Reconstrução, Análise e Predição de Ataques Cibernéticos: Uma abordagem de Mineração de Processos sobre a Base COMISET

João P. R. Esteves, Bruno Bogaz Zarpelão, Sylvio Barbon Junior, Rodrigo Sanches Miani
{joao.esteves, miani}@ufu.br; brunozarpelao@uel.br; sylvio.barbonjunior@units.it

WTDCC
Workshop de Teses e Dissertações em Ciência da Computação
2026

RESUMO

A Mineração de Processos (MP) reconstrói o encadeamento de atividades a partir de eventos agrupados em casos. Em *logs* de sistema não há um identificador de caso natural (como em processos de negócio), e a forma de defini-lo determina o que se revela sobre um ataque. Este trabalho trata a modelagem da noção de caso como objeto de investigação na COMISET, base pública com cerca de 250 milhões de eventos Windows rotulados segundo a MITRE ATT&CK®. Os *logs* resultantes são avaliados quanto à fidelidade com que reconstroem o comportamento atacante e à capacidade de antecipar suas próximas etapas.

Cenário	Alertas	Total de Linhas	Proporção
LAB	1.713.709	49.914.325	3.43%
REAL	631.606	202.304.794	0.31%

Tabela 1: Resumo da Cardinalidade da COMISET

INTRODUÇÃO

Ataques cibernéticos desdobram-se em etapas encadeadas no tempo e distribuídas entre processos e máquinas. A correlação de alertas já explora essas dependências por meio de grafos de ataque ou janelas temporais (Wang et al. [1]). Ela mantém, porém, implícito *o que* constitui uma instância de ataque, além de tipicamente produzir a representação de um incidente isolado.

A MP é complementar: ao agrupar eventos em casos, descobre modelos que generalizam sobre muitas execuções e os avalia com métricas consolidadas (van der Aalst [2]). Em cibersegurança, seu uso ainda é incipiente e parte de casos definidos *ad hoc* (Macak et al. [3]), embora a escolha do caso altere o *log* e os modelos obtidos (González López de Murillas et al. [4]). Investiga-se, portanto, quais noções de caso permitem que a MP revele a estrutura da atividade maliciosa.

MATERIAIS E MÉTODOS

Utiliza-se a COMISET (Pérez-Sánchez et al. [5]), com dois cenários: um laboratório com ataques controlados (LAB) e uma rede universitária em uso cotidiano (REAL). Os eventos maliciosos são rotulados por regras mapeadas à ATT&CK, o que os aproxima de alertas de um detector por assinaturas (IDS - *Intrusion Detection System*).

O método articula três etapas (Fig. 1). Na modelagem, constroem-se *event logs* sob diferentes noções de caso, a começar pela replicação de De Alvarenga et al. [6]. Na análise, a MP descobre modelos e variantes, confrontados com a cadeia de ataque documentada. Na predição, modelos de Aprendizado de Máquina (AM) treinados sobre os logs antecipam a próxima atividade maliciosa (Ceravolo et al. [7]).

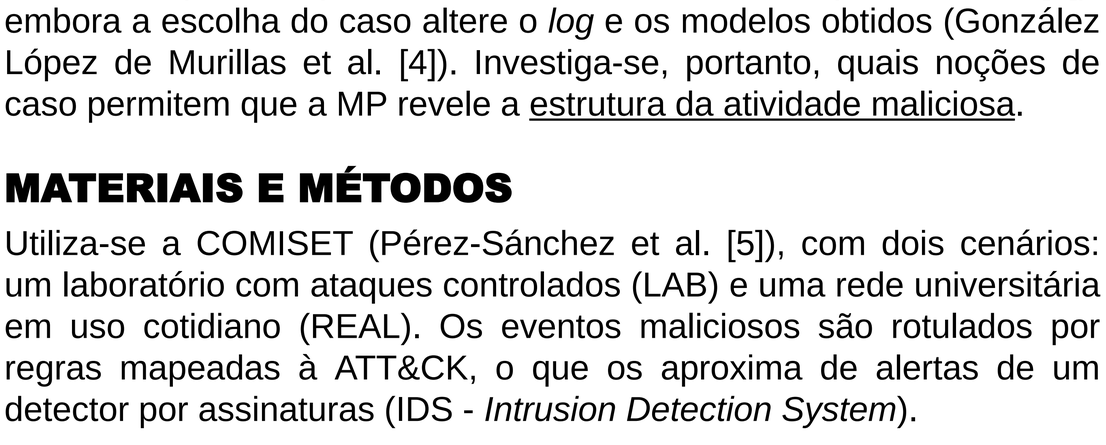


Figura 1: Etapas do Método

RESULTADOS PRELIMINARES

A engenharia de dados está concluída. Uma primeira modelagem, por identificador único e global de processo (GUID), cobriu >99% dos eventos, mas isolou 44% dos casos em um único evento e produziu um modelo ilegível (Fig. 2).

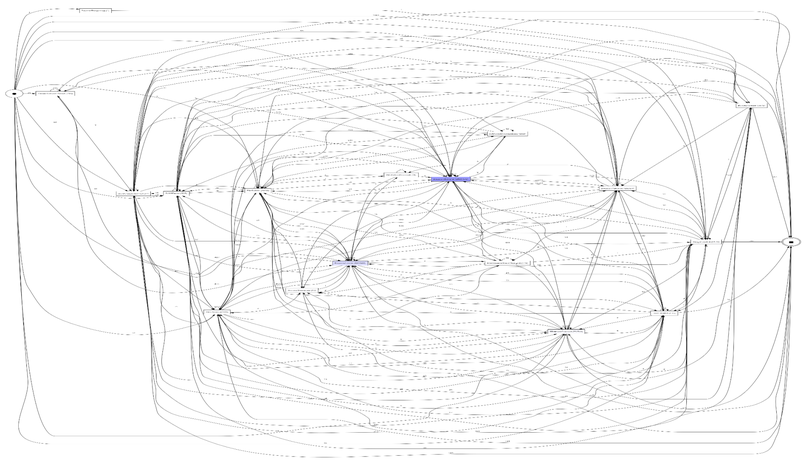


Figura 2: Exemplo de Modelo de Processo "*spaghetti*" (LAB)

A replicação de De Alvarenga et al. [7] revelou o limite oposto. Na COMISET, coletada no *host*, o IP só existe em eventos de rede, e >99% das conexões rotuladas no LAB são de saída. Restrita ao tráfego de entrada (como no original), a modelagem por endereço IP de atacante reduz 1,7 milhão de alertas a modelos bastante simplificados (Fig. 3).

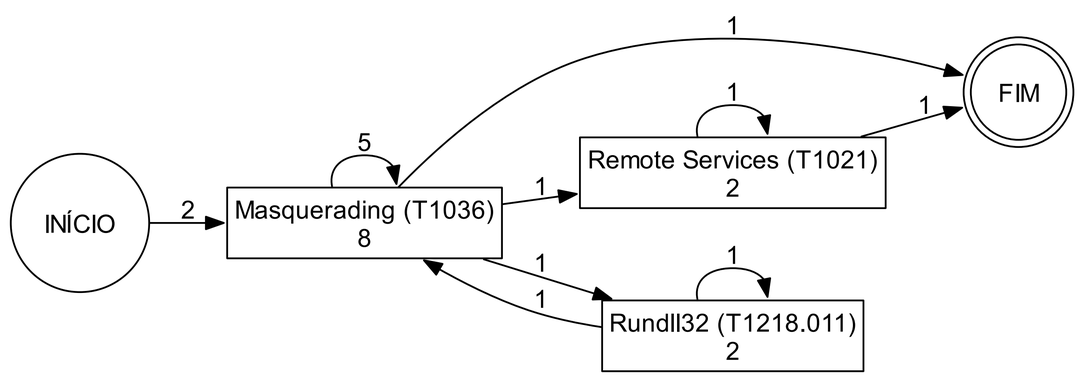


Figura 3: Exemplo de Modelo de Processo descoberto (LAB)

CONCLUSÃO E TRABALHOS FUTUROS

Até o momento, conclui-se que o IP agrega pouco e o GUID fragmenta demais. Espera-se que noções intermediárias produzam modelos mais legíveis e que sustentem predição da próxima atividade maliciosa por AM. Pretende-se consolidar um *pipeline* de modelagem que permita, como objetivo maior, interpretar as atividades maliciosas como uma trajetória.

Todo o trabalho desenvolvido até o momento, incluindo *notebooks* reprodutíveis e extensa documentação, pode ser encontrado no meu GitHub, no endereço https://github.com/jpramires/mestrado.

BIBLIOGRAFIA

[1] Wang, L., Liu, A., & Jajodia, S. (2006). *Using attack graphs for correlating, hypothesizing, and predicting intrusion alerts*. Computer Communications, 29(15).
[2] Van Der Aalst, W. (2016). *Process Mining - Data Science in Action*. Springer Berlin Heidelberg.
[3] Macak, M., Daubner, L., Sani, M. F., & Buhnova, B. (2022). *Cybersecurity Analysis via Process Mining: A Systematic Literature Review*. Advanced Data Mining and Applications (V. 13087, p. 393-407). Springer International Publishing.
[4] De Murillas, E. G. L., Reijers, H. A., & Van Der Aalst, W. M. P. (2020). *Case notion discovery and recommendation: Automated event log building on databases*. Knowledge and Information Systems, 62(7).
[5] Pérez-Sánchez, A., Palacios, R., & López, G. L. (2025). ***COMISET: Dataset for the analysis of malicious events in Windows systems***. Data in Brief, 61, 9.
[6] Sean Carlisto De Alvarenga, Barbon, S., Miani, R. S., Cukier, M., & Zarpelão, B. B. (2018). ***Process mining and hierarchical clustering to help intrusion alert visualization***. Computers & Security, 73.
[7] Ceravolo, P., Comuzzi, M., De Weerdt, J., Di Francescomarino, C., & Maggi, F. M. (2024). *Predictive process monitoring: Concepts, challenges, and future research directions*. Process Science, 1(1), 22.

AGRADECIMENTOS

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES) - Código de Financiamento 001.